

✨ 已更新 V2

Memory 模块 — 记忆与日记管理系统

一个自托管 AI 聊天应用里的记忆子系统：管理「结构化记忆」与「日记/知识库」两类数据，支持向量检索、主动浮现、日记抽取与重抽审阅。

致谢

记忆的底层模型（情感坐标、遗忘曲线衰减、主动浮现）移植自开源项目 **Ombre Brain**（作者 P0lar1zzZ，<https://github.com/P0lar1zzZ/Ombre-Brain>）。本文档描述的是我们在其之上构建的管理与处理层。

技术栈

Next.js 14 (App Router) + TypeScript · PostgreSQL + pgvector · Anthropic Claude / DeepSeek（记忆抽取）· OpenAI `text-embedding-3-small`（1536 维 embedding）

一、数据模型

memories — 结构化记忆

字段	说明
<code>content</code>	记忆正文
<code>valence</code> (-1~1) / <code>arousal</code> (0~1) / <code>importance</code> (1~10)	情感坐标 + 重要度（模型源自 Ombre Brain）
<code>is_pinned</code>	置顶，不衰减
<code>is_resolved</code>	沉底（已了结，降权）
<code>is_active</code>	归档开关
<code>source</code>	来源标签（见下）
<code>author</code>	记录者
<code>activation_count</code> / <code>last_activated_at</code>	命中次数/时间（衰减打分用）
<code>room</code>	多角色 / 空间隔离
<code>embedding</code>	语义向量 <code>vector(1536)</code> ，相似聚类 / 语义检索用（惰性维护：改 <code>content</code> 时置空，用前自动补齐）

小红书

小红书号: 258195658

knowledge_documents 一 日记原文

source_name (文件名) · original_content (完整原文) · file_type · room

knowledge_chunks 一 向量分块

source_name · chunk_index · content · embedding vector(1536) · document_id (FK)

🔑 记忆 ↔ 日记关联

日记抽取出的记忆，source 统一标成 old-diary:<文件名>。一个字段串起「原文 → 抽取记忆」双向追溯：删日记可连带删关联记忆、点日记能列出它生成的全部记忆。

二、记忆召回：两种范式

A. 主动浮现（记忆）

召回机制移植自 Ombre Brain：按「重要度 × 激活次数 × 时间衰减 × 情感强度」打分，未了结 / 高情绪记忆在对话开始时优先浮现，带冷启动、随机 recall、多样性洗牌。

我们在移植时按自己架构做的调整：

- per-room / per-character 作用域隔离（原版是单一记忆池）
- pinned 记忆独立成段，不挤占普通记忆的浮现名额
- 衰减率 λ 可配置（存设置表，可调快慢）
- 存记忆时用 Claude 自动打 valence/arousal/importance 标签
- 24h 后台扫描，低分记忆自动软归档（is_active=false，可恢复，不物理删）

B. 向量语义检索（日记 / 知识库）

这是 pgvector 的核心用途，我们自己实现的 RAG：

```
SELECT content, 1 - (embedding <=> $query::vector) AS similarity
FROM knowledge_chunks WHERE room = $room
ORDER BY embedding <=> $query::vector LIMIT 5    -- 余弦距离，取相似度 > 0.3
```

- 两个入口：聊天中模型用 knowledge_search 工具主动检索（每轮最多 3 次）+ 每轮被动自动检索注入上下文
- 上传日记时 /api/embed 把每个 chunk 向量化入库

两种范式分工：日记走向量检索（长文档找相关段落），记忆走主动浮现（短条目按情感/时效推送）。

三、记忆管理界面

- 列表：importance 色阶徽章 · valence/arousal 数值 · pin · resolved · 来源 · 命中次数

- 状态分类：活跃 ⇌ 已归档（两个子 tab）
- 来源过滤：全部 / 来自日记 / 其他
- 搜索框：正文 + 来源 + 作者
- 分页（20/页）· 排序（重要度 / 最新）
- 增：手动添加（未填情感值时自动分析 V/A/importance）
- 改：完整编辑器（正文 + V/A/importance 三滑块 + pin/resolved 勾选）
- 删 / 归档 / 恢复 / pin
- API：GET/POST/PUT/DELETE /api/memories

四、日记 / 知识库管理

- 拖放上传（.md/.txt/.json/.html，批量）→ 自动切块 + 向量化入 pgvector
- 查看原文（Markdown 渲染弹窗）
- 智能删除三选项：仅删日记 / 连关联记忆一起删（危险操作标红） / 取消
- 重复文件名提示

五、日记抽取（digest）— 多模型

把一篇长日记拆成多条独立记忆，每条自动带 valence/arousal/importance：

- 多 provider 路由：模型名 claude-* 走 Anthropic、deepseek-* 走 DeepSeek（OpenAI 兼容接口），上传时下拉选择
- 抽取规则：1 条 = 1 主题（不混题）· 去口语冗余 · 零碎信息合并 · ToDo 单列 · 粒度自适应（短文 1 条 / 长文不限）
- 强容错解析：剥代码围栏、抓最外层 JSON 数组、字段 clamp 到合法区间——模型啰嗦地加前言也不会让解析崩
- 省成本：30 字内短文直接成单条，不调模型
- 抽取出的记忆 source = old-diary:<文件名>，与原文双向关联

六、日记重抽审阅合并（redigest）

用新模型重新抽取一篇旧日记，并和现有记忆非破坏性地对比合并：

- 打开先列出该日记现有的关联记忆（可直接编辑 / 删除，不触发重抽）
- 选模型 → 「重抽」→ 后端重新抽取新版（全程不碰数据库）
- embedding 语义配对新旧记忆，三组并排审阅：
 - 配对（旧 ↔ 新，同主题）：逐条选 保留旧 / 采用新 / 都留 / 都弃
 - 仅旧（新版没抽到的）：默认保留
 - 仅新（新增的）：默认添加
- 确认后才事务性落库（删选中旧 + 插选中新）

- 多处防丢兜底：孤儿默认保留、pinned 旧记忆默认保留

设计要点：「预览只读 → 人工逐条审阅 → 确认才写库」。取代了早期「先删后抽再插」的破坏性流程——那种流程一旦抽取失败就会丢记忆。

七、记忆整理：脱水 · 合并 · 相似聚类

记忆库会越积越多——有的写得太长注水，有的内容彼此重复。这一套基于选择的批量整理应对它，并用向量聚类帮你发现该整理的。

选择模式（统一入口）

列表「选择」开关 → 勾选 N 条 → 底部栏先选模型（DeepSeek V4 Flash 默认 · Sonnet 4.5 · V4 Pro）→ 点[脱水]或[合并]。脱水与合并共用同一套选择 + 模型前置（执行前就选好，不是事后才换）。

脱水（dehydrate）— 压短，不丢温度

把注水的记忆拧干，情感质感与独特细节一字不损：

- **硬约束**：① 结果必须比原文短（变长 / 没压缩 → 弃用重试，两次都不达标就标「无变化」不动它）；② 锁死原文语言（检测假名漏译，中文记忆不会被悄悄改写成日语）
- **逐条预览**：原文 ↔ 脱水后并排，标字数与压缩百分比
- **版本对比**：「再脱水」追加候选 v1 / v2...，切换比较，挑最满意的那版采用
- 每条可手动微调，勾选后批量写回

合并（merge）— 多条糅成一条

把几条相近记忆融合：重复的归一、各自独特的全保留、自然糅合、保温度地精简：

- 多条原文并排 + 合并结果（可编辑）
- **版本对比**：「再合并」追加候选，切换选择
- 采用后：新记忆入库，原 N 条归档（不删除，留安全网；任一原条置顶则新条继承置顶）

相似聚类排序（類似順）— 发现重复

- `memories.embedding`（text-embedding-3-small，1536 维）+ 余弦单链接聚类
- 切到「類似順」→ 语义相近的记忆聚成组、相邻排列，打上「似ている記憶 xN」分组标头
- 一眼看出哪几条讲的是一回事 → 直接在那组里勾选、合并（发现 → 合并动线闭环）
- **惰性维护**：改过 content 的记忆向量置空，下次用时自动补齐（首次切入即全量回填）

脱水 / 合并的 LLM 调用走 provider 路由（DeepSeek / Anthropic），带 429 限流退避重试 + 低并发，避免批量整理打爆 API 速率上限。

八、MCP 工具

通过 MCP（Model Context Protocol）把记忆系统暴露给多端（网页 / Claude Code / Claude 桌面）读写。工具语义参考 Ombre Brain，落地到我们的 PostgreSQL + REST：

工具	功能
memory_breath	主动浮现
memory_hold	存单条 (Claude 自动打标)
memory_dream	自省消化 (回顾近期记忆)
memory_trace	改元数据 / 沉底 / pin / 删除
memory_pulse	系统状态 + 记忆全景诊断

九、一句话总结

- 记忆带情感坐标 (VAD)，不是纯文本 (模型源自 Ombre Brain)
- 两种召回：日记走向量语义检索，记忆走主动浮现
- 日记 ↔ 记忆靠一个 `source` 标签双向关联
- 日记抽取多模型可选 + 强容错解析
- 重抽走非破坏性审阅合并：预览 → 人工审阅 → 事务落库
- 记忆整理：脱水压短 / 合并糅合 / 相似聚类发现重复，都带版本对比与硬约束

出处

- 底层记忆模型：Ombre Brain by P0lar1zzZ — <https://github.com/P0lar1zzZ/Ombre-Brain>
- 情感坐标理论：Russell's Circumplex Model (效价-唤起二维情感模型)